

Prompts utilizados no Chatbot Dracarys

Documentação detalhada das decisões de prompt engineering do Desafio 2.

System Prompt

Você é o assistente virtual da seguradora Dracarys, especializado em atendimento a segurados.

Sua missão é responder dúvidas sobre apólices, sinistros, coberturas, regulamentação e procedimentos.

REGRAS INVIOLÁVEIS:

1. Responda APENAS com base no contexto fornecido entre as tags <contexto>. Se a informação não estiver no contexto, informe que não sabe.
2. Nunca invente coberturas, valores, prazos ou procedimentos.
3. Sempre cite a fonte ao final da resposta, no formato: "Fonte: [nome do documento]".
4. Linguagem clara, em português do Brasil, tom acolhedor e profissional. Evite jargões.
5. Para sinistros graves (acidente, óbito, roubo), sempre oriente o contato imediato com o departamento de sinistros.
6. Não faça promessas de cobertura ou pagamento – apenas informe o que os documentos permitem.

FORMATO DA RESPOSTA:

- Resposta direta e objetiva
- Quando houver passos (ex: como abrir um sinistro), use lista numerada
- Termine com a citação da fonte

User Prompt Template

```
<contexto>
{context}
</contexto>
```

Pergunta do segurado: {question}

Responda seguindo as regras do sistema, citando a fonte ao final.

Decisões de prompt engineering

Persona explícita

"**assistente virtual da seguradora Dracarys**" — dá identidade ao bot e estabelece o tom esperado.

Regras "invioláveis"

A palavra "inviolável" funciona como instrução de alta prioridade. Modelos open source 27B-32B respondem bem a esta marcação semântica.

Anti-alucinação por delimitadores

O contexto recuperado vem dentro de `<contexto>...</contexto>`. Isso: - **Marca onde está a fonte de verdade** (modelo não confunde com a pergunta) - **Permite recusa explícita** quando o contexto não tem a resposta - Compatível com a estratégia de RAG da Aula 04 do curso

Recusa estruturada

Mensagem padrão de "não encontrei" é literal — evita o modelo inventar variações criativas que possam soar como conhecimento real.

Citação obrigatória de fonte

Forçar `Fonte: [nome do documento]` ao final: - Aumenta auditabilidade - Permite ao usuário verificar a informação - Reduz percepção de "caixa-preta"

Orientação de segurança

A regra 5 sobre sinistros graves força o bot a sempre direcionar ao canal humano em casos críticos, evitando responsabilidade indevida do chatbot em situações de emergência.

Temperatura baixa (0.2)

- Reduz criatividade no LLM (queremos precisão, não originalidade)
- Aumenta consistência entre execuções da mesma pergunta
- Adequado para FAQ — alta temperatura = risco de divergência factual

Top-K = 6

- Trade-off entre cobertura (mais chunks = mais info) e ruído (chunks irrelevantes confundem)
- 6 chunks de ~800 chars = ~4.8K tokens de contexto + prompt + resposta cabe folgadoamente em 8K de contexto

Chunk size 800 + overlap 150

- Chunks de 800 chars = ~200-250 tokens cada — granularidade suficiente para FAQs
- Overlap de 150 chars (~20%) evita cortar respostas em pontos críticos
- Separadores PT-BR específicos: `["\n\n", "\n", ". ", "! ", "? ", "; ", ", ", " ", ""]`

Alternativas consideradas mas rejeitadas

Chain-of-Thought explícito

Não foi adicionado pois: - Em FAQ direto, raciocínio passo-a-passo gera respostas mais longas sem ganho factual - Modelos 27B costumam responder bem direto

Function calling para citações

Considerarei usar function calling para retornar JSON estruturado com `{answer, sources}`.
Rejeitado: - gemma2:27b não tem function calling nativo no Ollama - Adicionaria complexidade sem benefício claro para o usuário final

Multiple turn refinement (HyDE)

HyDE (Hypothetical Document Embedding) — gerar uma resposta hipotética antes do retrieval — pode melhorar recall em 5-15%. Não usado: - Adiciona uma chamada extra ao LLM (latência dobra) - Em FAQ de seguros, perguntas costumam usar vocabulário similar aos documentos

Reranking (bge-reranker-v2-m3)

Considerado mas não implementado por questão de tempo. Ficou nos próximos passos.